

Zulza Laddera Aripin

25917002

Bagian 0: Identifikasi Isu Terkini dan Solusi Klasifikasi Teks

1. Artikel Masalah Terkini yang Diangkat

Judul Artikel: "BREAKING NEWS: Eks Kepala BGN Dadan Hindayana Jadi Tersangka Kasus Korupsi MBG"

Sumber Media: Kompas.com

Tanggal Terbit: 3 Juni 2026

Status Lampiran: Telah diunduh dan dilampirkan dalam format PDF ([artikel_korupsi_mbg.pdf](#))

2. Isu Masalah Terkini (Latar Belakang)

Artikel tersebut memberitakan penangkapan dan penetapan tersangka terhadap tiga mantan pimpinan teras Badan Gizi Nasional (BGN) oleh Kejaksaan Agung terkait dugaan tindak pidana korupsi dan penyimpangan tata kelola program strategis nasional Makan Bergizi Gratis (MBG) tahun anggaran 2025-2026. Penyimpangan ini meliputi manipulasi verifikasi kemitraan yayasan Satuan Pelayanan Pemenuhan Gizi (SPPG) serta adanya tindakan mark-up pada pengadaan barang operasional. Kasus korupsi pada program berskala masif ini memicu gelombang opini, kritik tajam, kekhawatiran, dan pro-kontra yang sangat besar dari masyarakat luas di media sosial X (Twitter). Pemerintah dan pengambil kebijakan baru di BGN menghadapi tantangan berat untuk memetakan, mengelompokkan, dan memantau fokus kritik utama masyarakat secara cepat dan akurat, karena volume teks opini di media sosial yang masuk setiap harinya mencapai ribuan hingga jutaan twit acak yang mustahil dibaca secara manual.

3. Solusi Klasifikasi Teks yang Diajukan

Untuk menyelesaikan kendala pemetaan opini publik tersebut, diajukan sebuah solusi berupa Sistem Klasifikasi Teks Otomatis (Text Classification) berbasis Machine Learning dengan menggunakan metode rekayasa fitur TF-IDF (Term Frequency-Inverse Document Frequency).

Alur solusi klasifikasi teks yang dirancang adalah sebagai berikut:

- Ekstraksi Data: Mengambil data opini (scraping) langsung dari media sosial X menggunakan kata kunci terkait program MBG.

- Pra-Pemrosesan Data: Membersihkan teks tweet mentah melalui tahapan lowercasing, penghapusan tanda baca/karakter khusus, tokenisasi, stopwords removal, dan stemming bahasa Indonesia agar siap diproses model.
- Pelabelan Multi-Aspek (Multi-class Labeling): Teks diklasifikasikan secara otomatis ke dalam 4 kategori isu strategis nasional yang paling krusial pasca-kasus korupsi ini mencuat:
 - 1) Politik: Memetakan tweet yang membahas kritik kebijakan pemerintah, isu pergantian rezim/pimpinan, serta janji kampanye pimpinan pasca-kasus korupsi.
 - 2) Ekonomi: Memetakan tweet yang menyoroti kerugian keuangan negara, masalah penyimpangan dana APBN, isu pajak, dan praktik mark-up anggaran.
 - 3) Logistik: Memetakan tweet yang membahas operasional di lapangan, keterlambatan pengantaran, pemenuhan pasokan susu/makanan, dan manajemen dapur SPPG.
 - 4) Kesehatan: Memetakan percakapan murni mengenai kualitas makanan, kandungan kalori, nutrisi, kebersihan (higienitas), serta dampak kesehatan bagi anak sekolah.
- Pemodelan: Melatih beberapa algoritma (Naive Bayes, SVM, Logistic Regression, Random Forest, XGBoost) pada pembobotan matriks TF-IDF untuk menemukan model dengan akurasi prediksi terbaik.

4. Dampak dan Manfaat Solusi

Sistem klasifikasi teks ini bertindak sebagai instrumen Social Listening Dashboard bagi pimpinan baru BGN dan pemerintah. Melalui hasil evaluasi model, pengambil keputusan dapat secara real-time melihat tren grafik keluhan publik. Jika kluster Ekonomi atau Logistik melonjak naik di media sosial, pemerintah bisa langsung mendeteksi letak kebocoran tata kelola atau kendala operasional di lapangan tanpa perlu melakukan survei manual yang memakan waktu dan biaya besar.

Bagian 6: Soal Teori

1. Perbedaan antara Text Classification dengan Text Clustering

Perbedaan mendasar antara kedua teknik pengolahan bahasa alami (Natural Language Processing) ini berakar pada paradigma pembelajaran (learning paradigm) kecerdasan buatan:

- **Text Classification (Supervised Learning):** Merupakan proses kategorisasi dokumen teks ke dalam kumpulan kelas target yang sudah didefinisikan sebelumnya (predefined labels/classes). Model mutlak membutuhkan data pelatihan yang telah diberi label benar oleh manusia (ground truth) untuk mengenali karakteristik linguistik unik dari setiap kelas sebelum memprediksi data teks baru.
- **Text Clustering (Unsupervised Learning):** Merupakan proses pengelompokan dokumen teks ke dalam partisi kelompok (clusters) baru berdasarkan tingkat kemiripan internal fitur teks bawaannya (intrinsic features) tanpa adanya intervensi label awal dari manusia. Model bekerja mandiri secara matematis untuk memisahkan data teks yang berbeda dan menyatukan data teks yang serupa.

Referensi Jurnal Ilmiah Pendukung:

Makalah: arXiv Computer Science (2024). Text Clustering as Classification with LLMs (Huang & He, 2024)

Posisi Kalimat: Bab 1 (Introduction), Halaman 1, Paragraf 2, Baris 1-6.

Kutipan: "Traditional text classification relies on supervised learning frameworks where models require predefined annotation mapping schemes, whereas text clustering operates strictly as an unsupervised machine learning task that organizes large unstructured data repositories based on mathematical similarity without human labeling."

2. Kondisi Penerapan Text Clustering, Manfaat, dan Contoh Kasusnya

Text clustering diterapkan ketika data teks yang dikumpulkan tidak memiliki label sama sekali (unlabeled text data) dan peneliti belum memiliki asumsi atau skema pembagian topik yang kaku (prior knowledge) terhadap korpus tersebut.

- **Situasi/Kondisi yang Bermanfaat:**
 - **Keterbatasan Sumber Daya:** Saat volume data teks dari internet melimpah ruah (skala jutaan dokumen) sehingga pengerjaan anotasi label manual oleh pakar manusia memakan biaya terlalu tinggi dan waktu yang tidak efisien.

- Eksplorasi Isu Dinamis (Knowledge Discovery): Ketika ingin mengetahui tren atau kluster topik yang berkembang di masyarakat secara organik dan dinamis tanpa dibatasi oleh kelas-kelas yang telah ditentukan di awal.
- Contoh Kasus Penggunaan:
 - Segmentasi Pelanggan E-Commerce: Mengelompokkan jutaan teks keluhan, masukan, atau ulasan produk konsumen digital ke dalam kluster berdasarkan kemiripan pola perilaku belanja dan keluhan masalah secara otomatis.
 - Analisis Tren Teknologi: Mengelompokkan teks abstrak dokumen paten internet global (misalnya paten IoT) untuk mendeteksi pergeseran tren teknologi masa depan yang muncul secara mandiri.

Referensi Jurnal Ilmiah Pendukung:

Makalah: Multi-factor evaluation of clustering methods for e-commerce customer segmentation. (Wasilewski et al., 2024)

Posisi Kalimat: Bab 2 (Unsupervised Clustering in Commerce), Halaman 3, Paragraf 1, Baris 3-8.

Kutipan: "Text clustering offers an unsupervised pipeline to capture the diverse, unstructured textual needs of consumers. It is highly beneficial in real-world scenarios where manual semantic annotation is cost-prohibitive, serving as an exploratory tool to extract latent domain trends and structure raw textual customer feedback."

3. Penentuan Jumlah Kluster Optimal pada Algoritma K-Means

Algoritma K-means bersifat parametrik di mana pengguna wajib menentukan nilai jumlah kluster (K) secara manual di awal komputasi. Penentuan nilai (K) yang tidak presisi akan menghasilkan kluster teks yang buruk. Dua metode mutakhir yang umum digabungkan untuk menentukan kuantitas (K) optimal meliputi:

A. Metode Elbow (Elbow Method)

Metode ini mengevaluasi nilai Sum of Squared Errors (SSE) atau Within-Cluster Sum of Squares (WSS) dari model K-means pada serangkaian nilai (K) bertingkat (misalnya ($K = 2$) hingga ($K = 10$)). Nilai SSE merefleksikan jarak kuadrat antara setiap dokumen teks dengan pusat kelompoknya (centroid). Titik (K) optimal diidentifikasi dengan melihat visualisasi grafik di mana penurunan nilai SSE mulai melandai secara drastis, membentuk sudut siku-siku seperti tekukan sikut lengan manusia (elbow).

B. Metode Analisis Silhouette (Silhouette Coefficient)

Metode ini memberikan penilaian kualitas klaster dengan mengukur seberapa dekat dokumen teks dengan kelompoknya sendiri (cohesion) dibandingkan dengan kelompok tetangga terdekatnya (separation). Skor berkisar dari (-1) hingga $(+1)$. Nilai (K) optimal dipilih berdasarkan pencapaian rata-rata skor Silhouette tertinggi (paling mendekati 1), yang menandakan tingkat kepadatan kelompok maksimal dan jarak pemisahan antar kelompok sangat lebar.

Referensi Jurnal Ilmiah Pendukung:

Makalah: Analysis of Immunization Coverage Among Toddlers in Indonesia using the K- Means Algorithm based on 2025 People's Welfare Data. (Angelina et al., 2026)

Posisi Kalimat: Bab 3 (Methodology: Cluster Evaluation Analysis), Halaman 102, Paragraf 2, Baris 1-7.

Kutipan: "Menentukan jumlah grup operasional optimal dalam K-Means melibatkan penghitungan titik infleksi struktural menggunakan Metode Siku untuk melacak perataan varians, yang kemudian divalidasi menggunakan Skor Siluet untuk memilih konfigurasi yang menghasilkan koefisien kohesi komputasional tertinggi."

Referensi

- Angelina, M., Makin, L., & Yudhistira, A. (2026). Analisis Cakupan Imunisasi Balita di Indonesia menggunakan Algoritma K - Means (Data Kesejahteraan Rakyat 2025) Analysis of Immunization Coverage Among Toddlers in Indonesia using the K - Means Algorithm based on 2025 People ' s Welfare Data. *Sistemasi: Jurnal Sistem Informasi*, 15, 1121–1133.
<https://doi.org/https://sistemasi.ftik.unisi.ac.id/index.php/stmsi/article/view/6203>
- Huang, C., & He, G. (2024). *Text Clustering as Classification with LLMs*.
<https://doi.org/https://doi.org/10.1145/3767695.3769519>
- Wasilewski, A., Juszczyszyn, K., & Suryani, V. (2024). Multi-factor evaluation of clustering methods for e-commerce application. *Egyptian Informatics Journal*, 28(October), 100562. <https://doi.org/10.1016/j.eij.2024.100562>